



Universidad de las Américas Puebla (UDLAP)

Licenciatura en Ciencia de Datos

Actividad 8: Procesamiento de Lenguaje Natural

Andrea Hernandez Huerta
ID: 175523

Heriberto Espino Montelongo
ID: 175199

Profesor: Dr. Victor Giovanni Morales Murillo

Curso: Programación Concurrente

Fecha de entrega: 25 de septiembre de 2026

Mucha información se encuentra expresada en *lenguaje natural*: publicaciones en redes sociales, mensajes, documentos, reseñas o transcripciones. Estos textos se consideran principalmente *datos no estructurados*, por lo que no pueden ser utilizados directamente por la mayoría de los algoritmos. Aquí aparece el **Procesamiento de Lenguaje Natural (PLN)**, que busca desarrollar métodos para representar, analizar y generar lenguaje humano.

El texto se divide en *tokens*; posteriormente, un *embedding* asigna a cada token un vector para representar relaciones, permitiendo usar medidas de similitud, como la similitud de coseno. A partir de estas representaciones pueden realizarse, entre otras, las siguientes tareas:

1. **Clasificación y análisis de sentimientos:** determinar el tema, intención o polaridad de un texto.
2. **Sistemas de recomendación:** utilizar contenido mediante similitudes entre vectores, filtrado colaborativo mediante matrices usuario-ítem y factorización matricial, o combinaciones híbridas.
3. **Generación de lenguaje:** predecir sucesivamente nuevos tokens condicionados por el contexto anterior.

Una conexión importante entre PLN y programación concurrente aparece en los *Transformers*. Antes de éstos, el procesamiento dependía de *RNNs*, que pueden presentar problemas de *vanishing* y *exploding gradients*. Arquitecturas *seq2seq*, mediante *LSTMs* y mecanismos anteriores de atención ayudaron a resolver parte de estas limitaciones. Vaswani et al. (2017) propusieron el Transformer, eliminando la recurrencia y permitiendo paralelismo en distintas posiciones de una secuencia, calculando tres proyecciones denominadas *queries*, *keys* y *values*. Los Transformers actuales pueden organizarse como modelos *encoder-decoder*, como el trabajo original; *encoder-only*; o *decoder-only*, familia a la que pertenece Chat (Sanderson 2017; Starmer 2022).

Desde la **lingüística computacional**, el lenguaje también puede estudiarse en distintos niveles:

1. **Fonética y fonología:** estudian los sonidos organización dentro de una lengua, para reconocimiento de voz.
2. **Morfología:** estudia la estructura interna de las palabras. Permite, por ejemplo, la *lematización*, *cantábamos* → *cantar*, o el *stemming*, { *trabajando*, *trabajadores* } → *trabaj*.
3. **Sintaxis:** estudia cómo se relacionan las palabras dentro de una oración. “*Mary saw the man with a telescope*”.
4. **Semántica y pragmática:** estudian el significado y su dependencia del contexto. “*Fui al Banco*”.

La calidad de los datos es súper importante. Si las transcripciones o etiquetas utilizadas durante el entrenamiento son incorrectas, el modelo optimizará su función de pérdida respecto de información incorrecta. Este problema se intensifica cuando existen pocos datos.

Por ello, la importancia del PLN en México es doble. Es el país con mayor hablantes que hablan español, la cuarta lengua más hablada; y al mismo tiempo, tiene una enorme diversidad lingüística, con lenguas indígenas como náhuatl, maya, zapoteco o totonaco. Lo que plantea la necesidad de construir corpus, anotaciones y herramientas computacionales para lenguas que actualmente cuentan con muchos menos datos.

Referencias

- Sanderson, G. (5 de oct. de 2017). *Neural Networks*. 3Blue1Brown. URL: https://www.youtube.com/playlist?list=PLZHQObOWTQDNU6R1_67000Dx_ZCJB-3pi (visitado 25-09-2026).
- Starmer, J. (30 de oct. de 2022). *Neural Networks / Deep Learning*. StatQuest with Josh Starmer. URL: <https://www.youtube.com/playlist?list=PLblh5JKOoLUIxGDQs4LFFD--41Vzf-ME1> (visitado 25-09-2026).
- Vaswani, A., N. Shazeer, N. Parmar, J. Uszkoreit, L. Jones, A. N. Gomez, Ł. Kaiser e I. Polosukhin (2017). «Attention Is All You Need». En: *Advances in Neural Information Processing Systems*. Ed. por I. Guyon, U. von Luxburg, S. Bengio, H. Wallach, R. Fergus, S. V. N. Vishwanathan y R. Garnett. Vol. 30. Curran Associates, Inc. URL: https://proceedings.neurips.cc/paper_files/paper/2017/file/3f5ee243547dee91fbd053c1c4a845aa-Paper.pdf.